

DETR 系列目标检测方法

从 DETR、DINO 到 Grounding DINO

韩成瑞

东南大学数学学院

2026 年 7 月 22 日



- ① 传统目标检测概述
- ② DETR：集合预测与一对一匹配
- ③ DINO：改进查询初始化与去噪训练
- ④ Grounding DINO：开放词汇目标检测

报告脉络：一条不断解除人工先验的主线

传统检测	手工 anchor / proposal + 密集预测 + NMS 后处理
↓	用可学习 query 直接预测目标集合，去掉 NMS
DETR	object queries + 匈牙利匹配，但收敛慢、小目标弱
↓	动态 anchor、去噪训练、多尺度稀疏注意力
DINO	12 epoch 即达高精度，但类别仍是训练时固定的 C 个
↓	用文本特征替换固定分类器
Grounding DINO	开放词汇检测：类别 / 短语由输入文本动态给出

全篇主线

从“手工先验 + 局部候选”走向“端到端集合预测”，再走向“用语言定义要找的目标”。

- 1 传统目标检测概述
- 2 DETR：集合预测与一对一匹配
- 3 DINO：改进查询初始化与去噪训练
- 4 Grounding DINO：开放词汇目标检测

单阶段：YOLO 系列

$$\text{Head}(I) = \{p_{obj}, p(c | obj), b\}$$

- p_{obj} : 该位置是否包含任意前景目标
- $p(c | obj)$: 存在目标时的类别分布
- 经典 YOLO 类别得分: $p_{obj} p(c | obj)$

两阶段：R-CNN 系列

$$I \rightarrow \text{Proposals} \rightarrow \text{RoI Head}$$

- 第一阶段产生候选区域
- 第二阶段逐 RoI 分类并精修边界框
- 候选更稀疏，但流程更复杂

共同特征

传统方法产生大量候选，再用阈值和 NMS 合并。部分现代 YOLO 不再显式输出独立 objectness。

R-CNN 演进与 YOLO: 传统方法只需把握流程差异

方法	核心流程	解决的问题
R-CNN	Selective Search → 每个 proposal 单独过 CNN	将深度特征用于区域检测，但重复计算严重
Fast R-CNN	整图 CNN → RoI Pooling → 分类/回归	共享卷积特征，统一多任务训练
Faster R-CNN	共享 CNN → RPN → RoI Head	候选框生成也由网络学习
YOLO	整图 CNN → 密集预测 → NMS	将检测改写为一次前向的回归问题

- ① 传统目标检测概述
- ② DETR：集合预测与一对一匹配
- ③ DINO：改进查询初始化与去噪训练
- ④ Grounding DINO：开放词汇目标检测

基本信息

- **题目:** End-to-End Object Detection with Transformers
- **作者:** Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, Sergey Zagoruyko
- **机构:** Facebook AI
- **发表:** ECCV 2020 (arXiv:2005.12872, 2020 年 5 月)

主要作者信息

- **Nicolas Carion、Francisco Massa:** 论文共同第一作者, 工作完成于 Facebook AI;
- **Alexander Kirillov:** Mask R-CNN、Panoptic FPN 等代表性视觉工作的核心作者, 后续参与 Segment Anything;
- **Sergey Zagoruyko:** Wide Residual Networks 的主要作者, 研究方向涵盖视觉表征与目标检测。

来源: Carion et al., DETR, author list and author footnote

传统方法遗留的三处人工设计

- **Anchor / Proposal**: 需要手工设定尺度、长宽比，或额外网络生成候选；
- **密集预测**: 同一物体常被多个局部位置重复预测；
- **NMS 后处理**: 非端到端，依赖经验阈值去除重复框。

DETR 的思路

把检测重新表述为“图像 $\rightarrow$ 固定数量目标集合”的一次性映射，用一对一匹配取代启发式后处理，实现端到端训练。

DETR 的范式变化：直接预测最终目标集合





Fig. 1: DETR directly predicts (in parallel) the final set of detections by combining a common CNN with a transformer architecture. During training, bipartite matching uniquely assigns predictions with ground truth boxes. Prediction with no match should yield a “no object” ($\emptyset$) class prediction.

- 输入固定数量的 object queries，并行输出 N 个类别与边界框；
- 训练时通过二分图匹配建立**一对一对应**；
- 未匹配 query 预测特殊类别 $\emptyset$ ，推理阶段无需 anchor 与 NMS。

DETR 总体架构



- 1 CNN backbone 生成 $f \in \mathbb{R}^{C \times H \times W}$;
- 2 1×1 卷积降维并展平为 HW 个视觉 token;
- 3 Transformer encoder 建模全局图像关系;
- 4 Decoder 通过 object queries 并行寻找物体;
- 5 FFN 分别预测类别和归一化边界框 (c_x, c_y, w, h) 。

来源: Carion et al., DETR, Fig. 2 and Sec. 3.2

Encoder: 把二维图像特征变成全局上下文表示

Backbone 特征先投影并展平；二维位置编码在各注意力层中注入到 query/key:

$$Z_0 = \text{Flatten}(\text{Conv}_{1 \times 1}(f)), \quad Q = K = Z + P, \quad V = Z. \quad (1)$$

每层 encoder 使用标准多头自注意力:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V. \quad (2)$$

- Q, K, V 都来自图像 token，因此每个位置可聚合整幅图像信息；
- 二维正弦位置编码 P 保留空间关系，并在每层 encoder attention 中使用；
- 全局注意力有利于大目标和物体间关系，但复杂度约为 $O((HW)^2)$ 。

来源: Carion et al., DETR, Sec. 3.2

设第 l 层 query 表示为 $Q^{(l)} \in \mathbb{R}^{N \times d}$:

$$\bar{Q}^{(l)} = \text{SelfAttn}\left(Q^{(l-1)} + Q_{obj}\right), \quad (3)$$

$$Q^{(l)} = \text{CrossAttn}\left(\bar{Q}^{(l)} + Q_{obj}, Z_L + P, Z_L\right), \quad (4)$$

$$(\hat{p}_i, \hat{b}_i) = \text{Head}\left(q_i^{(L)}\right). \quad (5)$$

- Q_{obj} 是可学习的位置 embedding, 使不同槽位产生不同预测;
- query self-attention 协调各槽位的分工, 减少重复目标;
- cross-attention 从 encoder 特征中聚合与当前 query 相关的区域。

原始 DETR 的难点

Query 没有显式几何含义, 训练初期必须同时学会“去哪里看”和“预测什么”。

第一步：匈牙利算法寻找最优一对一匹配

将真值集合补齐为 N 个元素, $y_i = (c_i, b_i)$, 预测为 $\hat{y}_j = (\hat{p}_j, \hat{b}_j)$:

$$\hat{\sigma} = \arg \min_{\sigma \in \mathfrak{S}_N} \sum_{i=1}^N \mathcal{L}_{match}(y_i, \hat{y}_{\sigma(i)}) . \quad (6)$$

论文中的匹配代价为:

$$\mathcal{L}_{match}(y_i, \hat{y}_j) = -\mathbf{1}_{c_i \neq \emptyset} \hat{p}_j(c_i) + \mathbf{1}_{c_i \neq \emptyset} \mathcal{L}_{box}(b_i, \hat{b}_j). \quad (7)$$

与传统标签分配的区别

传统方法可让多个 anchor 匹配同一物体; DETR 在全局范围内寻找一对一分配, 从训练目标上抑制重复框。

来源: Carion et al., DETR, Eq. (1)

第二步：对匹配后的预测计算集合损失

匈牙利损失：

$$\mathcal{L}_{Hungarian} = \sum_{i=1}^N \left[-\log \hat{p}_{\hat{\sigma}(i)}(c_i) + \mathbf{1}_{c_i \neq \emptyset} \mathcal{L}_{box}(b_i, \hat{b}_{\hat{\sigma}(i)}) \right]. \quad (8)$$

边界框损失：

$$\mathcal{L}_{box}(b, \hat{b}) = \lambda_{L1} \|b - \hat{b}\|_1 + \lambda_{giou} \mathcal{L}_{GIoU}(b, \hat{b}). \quad (9)$$

- L_1 直接约束中心、宽和高；GIoU 提供尺度无关的重叠度量；
- $\emptyset$ 类别项降权，以缓解空槽位远多于目标的类别不平衡；
- 每层 decoder 都加入共享预测头和辅助 Hungarian loss，改善梯度传播。

来源：Carion et al., DETR, Eq. (2) and Sec. 3.2

为什么 DETR 可以取消 NMS ?

传统检测器

- ① 一个物体激活多个局部候选；
- ② 候选之间没有全局排他约束；
- ③ 推理后用 NMS 合并重复框。

DETR

- ① 每个真值只分配一个 query；
- ② Query self-attention 建模槽位间关系；
- ③ 重复框无法同时获得正监督。

核心条件

“一对一匹配 + query 间交互 + $\emptyset$ 类别” 共同实现集合级去重；只使用 Transformer 并不能自动取消 NMS。

原始 DETR 的结果与局限决定了后续改进方向

Model (R50)	Epochs	AP	AP_S	AP_M	AP_L
Faster R-CNN-FPN+	109	42.0	26.6	45.4	53.4
DETR	500	42.0	20.5	45.8	61.1

- 单尺度高层特征导致小目标性能明显偏低；
- 全局注意力处理高分辨率特征的计算、显存开销较高；
- Query 缺少空间先验，二分图匹配在训练早期不稳定，收敛需要 500 epochs。

后续主线

Deformable DETR 引入稀疏多尺度注意力；DAB-DETR 将 query 表示为 4D anchor box；DN-DETR 用去噪任务稳定匹配。DINO 将这些思想整合并继续改进。

来源：Carion et al., DETR, Table 1

- ① 传统目标检测概述
- ② DETR：集合预测与一对一匹配
- ③ DINO：改进查询初始化与去噪训练
- ④ Grounding DINO：开放词汇目标检测

基本信息


- **题目:** DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection
- **作者:** Hao Zhang, Feng Li, Shilong Liu, Lei Zhang, Hang Su, Jun Zhu, Lionel M. Ni, Heung-Yeung Shum
- **机构:** IDEA 研究院 (国际数字经济研究院)、清华大学、香港科技大学
- **发表:** ICLR 2023 (arXiv:2203.03605, 2022 年 3 月)

主要作者信息

- **Hao Zhang、Feng Li、Shilong Liu:** 论文共同第一作者, 原文注明作者顺序随机; 工作期间均在 IDEA 实习;
- **Lei Zhang:** 论文通讯作者, IDEA 研究院研究人员, 也是 DAB-DETR、DN-DETR 系列工作的主要推动者;
- **Jun Zhu:** 清华大学计算机系教授, 研究方向包括贝叶斯机器学习、生成模型与视觉学习;
- **Heung-Yeung Shum:** IDEA 研究院负责人, 长期从事计算机视觉与人工智能研究。

来源: Zhang et al., DINO, author list and author footnotes

DINO 不是推倒重来，而是把 DETR 的三条加速路线合到一起



- **Deformable DETR**: 围绕 reference box 在多尺度特征上稀疏采样，解决计算量与小目标问题；
- **DAB-DETR**: 把位置 query 显式写成动态 4D anchor (x, y, w, h) ；
- **DN-DETR**: 训练时额外加入带噪 GT queries，降低早期二分图匹配的不稳定性；
- **DINO**: 在这一强基线上改进 anchor 的选择、去噪判别与逐层框优化。

来源: Zhang et al., DINO, Fig. 2 and Sec. 3.1

理解 DINO 的关键：一个 query 同时包含“找哪里”和“找什么”

位置部分：anchor box

$$a_i^{(0)} = (x_i, y_i, w_i, h_i)$$

决定 deformable attention 从哪些尺度、哪些局部位置采样。

内容部分：content query

$$q_i^{(0)} \in \mathbb{R}^d$$

聚合目标外观，最终用于类别预测与框偏移回归。


三个改进对应三个问题

- ① **Mixed Query Selection**: 初始 anchor 从哪里来？
- ② **Contrastive DeNoising**: 多个相近 anchor 如何避免抢同一目标？
- ③ **Look Forward Twice**: 后层更准的框如何反向帮助前层？

训练与推理

普通 matching queries 始终存在；CDN queries 只在训练时作为辅助分支加入，推理时移除。

第一步 Mixed Query Selection: 先用 encoder 给出可靠的位置起点



对最后一层 encoder features X 做辅助分类与框回归，并选 top- K ：

$$\mathcal{I}_K = \text{TopK}(s_{obj}(X)), \quad b^{(0)} = g_{box}(X_{\mathcal{I}_K}), \quad q_{content} = Q_{learnable}. \quad (10)$$

- **Static**: 位置与内容均是图像无关的可学习参数；
- **Pure selection**: 位置和内容都取自 top- K encoder tokens，但单个 token 可能只覆盖物体局部或混合多个物体；
- **Mixed**: 仅用 encoder 输出初始化动态 anchor，content query 仍为可学习参数，再由 decoder 聚合完整目标。

问题：Top- K 选出的相近 anchor 会造成“匹配混淆”



Top- K 只按显著性排序选取，同一目标周围常同时出现多个高响应位置；训练早期，one-to-one matching 可能把较远的相邻 anchor 分配给真值。对每个真值 b_i ，找到最终与其匹配的 decoder 初始 anchor a_i ，论文用如下指标量化这种混淆：

$$\text{ATD}(k) = \frac{1}{k} \sum_{d \in \text{TopK}(D, k)} d, \quad D = \{\|b_i - a_i\|_1\}_{i=1}^N. \quad (11)$$

- ATD 越大，说明越多目标被远处的 anchor “抢走”；
- 普通 DN（去噪训练）只告诉网络“靠近 GT 的 anchor 应恢复目标”，没有显式教它拒绝稍远的 anchor；
- DINO 将这种选择困难称为 anchor confusion，并由此引入 CDN。

来源：Zhang et al., DINO, Eq. (1), Fig. 4 and Sec. 3.3

第二步 CDN 的解法：让相近 anchor 学会“靠近就恢复、稍远就拒绝”



以真值框 b_i 为中心生成两类 4D anchor; 令 $s(\epsilon)$ 表示论文定义的噪声尺度:


$$b_i^+ = b_i + \epsilon_i^+, \quad s(\epsilon_i^+) < \lambda_1, \quad (12)$$

$$b_i^- = b_i + \epsilon_i^-, \quad \lambda_1 < s(\epsilon_i^-) < \lambda_2. \quad (13)$$

- 内圈 b_i^+ : 预测原类别并回归到 b_i , 对应“靠近就恢复”;
- 环带 b_i^- : 分类为 $\emptyset$, 不重建 GT 框, 对应“稍远就拒绝”;
- 每个 GT 一正一负, 只训练时加入; 新增的负样本边界压低 ATD, 带来约 +1.3 小目标 AP 提升。

来源: Zhang et al., DINO, Fig. 3, Eq. (1) and Sec. 3.3

Look Forward Twice: 让后层损失同时改善“起点框”和“本层偏移”



DINO 的框更新公式为：

$$\Delta b_i = \text{Layer}_i(b_{i-1}), \quad b'_i = \text{Update}(b_{i-1}, \Delta b_i), \quad (14)$$

$$b_i = \text{Detach}(b'_i), \quad b_i^{(pred)} = \text{Update}(b'_{i-1}, \Delta b_i). \quad (15)$$

- Deformable DETR 层间 detach，第 i 层损失主要优化本层偏移 Δb_i ；
- DINO 保留未 detach 的 b'_i 参与相邻层预测，使后层损失可回传到前层；
- 同一框更新参与两次预测监督，故称“look forward twice”。

来源：Zhang et al., DINO, Eq. (2), Fig. 6 and Sec. 3.5

三项改进各解决一个环节，12 epochs 累积提升 1.4 AP

总体训练目标可写为：

$$\mathcal{L}_{total} = \mathcal{L}_{matching} + \lambda_{CDN} \mathcal{L}_{CDN} + \sum_{l=1}^L \lambda_l \mathcal{L}_{aux}^{(l)}. \quad (16)$$

Setting (12 epochs)	QS	LFT	CDN	AP
Strong baseline	Pure	–	–	46.5
+ mixed query selection	Mixed	–	–	47.0
+ look forward twice	Mixed	✓	–	47.4
DINO	Mixed	✓	✓	47.9

三项改进逐步叠加；完整 5-scale R50 模型达到 49.4 AP@12，24 epochs 达到 51.3 AP。

来源：Zhang et al., DINO, Tables 1, 2 and 4

DINO 解决了收敛与精度，但类别空间仍是封闭的

- DINO 的分类头是固定线性层 $W \in \mathbb{R}^{C \times d}$ ，类别数 C 在训练前就已确定；
- 遇到训练集之外的新类别，模型无法给出有意义的类别得分；
- 现实场景中的类别往往是开放的，且常以自然语言描述属性、关系等细节。

Grounding DINO 的切入点

保留 DINO 的检测框架（动态 anchor、去噪训练、逐层框优化），把“分类到固定类别”替换为“与输入文本做匹配”，从而支持开放词汇检测。

- ① 传统目标检测概述
- ② DETR：集合预测与一对一匹配
- ③ DINO：改进查询初始化与去噪训练
- ④ **Grounding DINO：开放词汇目标检测**

基本信息


- **题目:** Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection
- **作者:** Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, Lei Zhang 等
- **机构:** 清华大学、IDEA、香港科技大学、香港中文大学 (深圳)、微软研究院、华南理工大学
- **发表:** ECCV 2024 (arXiv:2303.05499, 2023 年 3 月)

主要作者信息

- **Shilong Liu:** 论文第一作者, 清华大学与 IDEA 团队成员; DAB-DETR 第一作者、DINO 共同第一作者;
- **Jun Zhu、Lei Zhang:** 论文通讯作者, 分别来自清华大学与 IDEA;
- **Feng Li、Hao Zhang:** DINO 共同第一作者, 并参与 Grounding DINO 的检测框架设计;
- **Chunyuan Li、Jianwei Yang:** 来自微软研究院, 参与视觉-语言模型与开放词汇检测研究。

来源: Liu et al., Grounding DINO, author list and author footnotes


Grounding DINO 的根本变化：类别由输入文本动态定义



- 闭集检测学习固定分类器 $W \in \mathbb{R}^{C \times d}$ ，输出只能属于训练时定义的 C 个类别；
- Grounding DINO 用文本 token 特征 X_T 代替固定分类器： $s_{it} = q_i^\top x_t$ ；
- 因而同一模型既可接收类别列表，也可接收含属性、关系的 referring expression；
- 输出为 $(\hat{b}_i, \text{matched phrase}_i)$ ，而不只是 $(\hat{b}_i, \hat{c}_i)$ 。

来源：Liu et al., Grounding DINO, Fig. 1

核心设计不是“加一个文本编码器”，而是在三个阶段持续融合语言



- ① **特征阶段**：Feature Enhancer 让图像 token 与文本 token 双向对齐；
- ② **query 初始化阶段**：文本相关性决定哪些图像位置成为候选 anchor；
- ③ **框精修阶段**：每层 decoder 同时读取图像与文本，更新跨模态 query；
- ④ **最终 query 回归框**，并与每个文本 token 做点积得到短语分数。

来源：Liu et al., Grounding DINO, Fig. 3 and Sec. 3

预备: Sub-sentence mask 让类别列表不再产生“伪上下文”




Fig. 4: Comparisons of text representations.

在做特征融合之前，文本编码器需要先把类别列表“cat . baseball glove .”变成 token 表示。对属于不同短语的 token 构造 attention mask：

$$M_{ij} = \begin{cases} 0, & i, j \text{ 属于同一短语,} \\ -\infty, & i, j \text{ 属于不同短语,} \end{cases} \quad A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}} + M\right)V. \quad (17)$$

这类列表并非自然句子；若允许全局 attention，类别顺序会产生无意义依赖。mask 保留短语内部的词级结构，同时阻断不同短语间交互，为后续融合提供干净的 X_T 。

来源：Liu et al., Grounding DINO, Fig. 4 and Sec. 3.4

阶段一：Feature Enhancer 先建立像素区域与词语之间的双向联系

设图像特征为 X_I ，文本特征为 X_T 。一层 feature enhancer 可概括为：

$$H_I = \text{DeformSA}(X_I), \quad H_T = \text{SA}(X_T), \quad (18)$$

$$\tilde{X}_I = H_I + \text{CA}(H_I, H_T, H_T), \quad (19)$$

$$\tilde{X}_T = H_T + \text{CA}(H_T, H_I, H_I). \quad (20)$$

- 图像内部：Deformable self-attention 聚合多尺度局部证据；文本内部：self-attention 建模词间上下文；
- 图像查询文本 (image-to-text)，使区域知道哪些词重要；文本查询图像 (text-to-image)，使词义落到视觉区域；
- 这一步发生在候选 query 产生之前，因此后续选择看到的已经是跨模态特征；
- 去掉 encoder fusion，LVIS zero-shot AP 从 16.1 降至 13.1，是三处融合中降幅最大的一项。

来源：Liu et al., Grounding DINO, Sec. 3.1 and Table 7

阶段二：Language-guided Query Selection 把“显著目标”改成“文本相关目标”

设：

$$X_I \in \mathbb{R}^{N_I \times d}, \quad X_T \in \mathbb{R}^{N_T \times d}, \quad d = 256.$$

每个图像 token 与全部文本 token 计算相似度，取其最相关词：

$$\mathcal{I}_{N_q} = \text{Top}_{N_q} \left(\text{Max}^{(-1)}(X_I X_T^\top) \right), \quad N_q = 900. \quad (21)$$

- ① $S = X_I X_T^\top \in \mathbb{R}^{N_I \times N_T}$ ：第 i 行是图像位置 i 对所有词的响应；
- ② $r_i = \max_t S_{it}$ ：只要该位置与提示中的某个词高度相关，就可进入候选；
- ③ 取 r_i 的 top-900，并由对应 encoder 输出预测初始 4D anchors；
- ④ 沿用 DINO 的 mixed selection：位置来自图像，content queries 仍是可学习参数。

来源：Liu et al., Grounding DINO, Eq. (1) and Sec. 3.2

阶段三：Decoder 交替回答“框在哪里”和“它对应哪个词”

对第 l 层 query，可将计算顺序概括为：

$$Q_s^{(l)} = \text{SelfAttn}(Q^{(l-1)}), \quad (22)$$

$$Q_I^{(l)} = \text{ImageCrossAttn}(Q_s^{(l)}, \tilde{X}_I), \quad (23)$$

$$Q_T^{(l)} = \text{TextCrossAttn}(Q_I^{(l)}, \tilde{X}_T), \quad (24)$$

$$Q^{(l)} = \text{FFN}(Q_T^{(l)}). \quad (25)$$

- Self-attention：queries 相互竞争/协同，抑制多个 query 重复解释同一目标；
- Image cross-attention：围绕当前 anchor 从多尺度图像特征取证并精修位置；
- Text cross-attention：让区域表征读取相关 token，形成可与短语匹配的 query；
- 相比 DINO，每层新增 text cross-attention；语言由此贯穿三个阶段。

来源：Liu et al., Grounding DINO, Sec. 3.3 and Table 7

最后一层 queries 与文本 token 的相似度矩阵：

$$S = Q^{(L)} \tilde{X}_T^\top \in \mathbb{R}^{N_q \times N_T}. \quad (26)$$

若短语 “a black cat” 对应某个 GT 框，则相关 token 构成正集合；其余 token 为负。训练目标为：

$$\mathcal{L}_{total} = \mathcal{L}_{contrastive}(S, Y_{phrase}) + \lambda_{L1} \mathcal{L}_1(b, \hat{b}) + \lambda_{giou} \mathcal{L}_{GIoU}(b, \hat{b}). \quad (27)$$

- 匈牙利匹配代价由 token-level 分类代价、 L_1 和 GloU 共同构成，仍保持 one-to-one set prediction；
- 匹配后，对每个 query-token logit 计算 focal loss，对匹配框计算 L_1 与 GloU；
- 每层 decoder 和 encoder 候选输出均有辅助损失；CDN 等 DINO 训练机制继续保留。

来源：Liu et al., Grounding DINO, Sec. 3.5

Grounded Pre-training 的本质：把不同数据统一成 region–phrase 对

检测数据 (I, b, c)

- 将一张图中的类别名拼成 prompt
- 建立 $b \leftrightarrow$ 类别 token 的正对应

Grounding / REC (I, b, p)

- 短语 p 与区域 b 天然配对
- 提供属性、关系与指代表达监督

Caption 数据 (I, s)

- 先由预训练模型产生 region–phrase 伪标签
- 扩展训练词汇和长尾概念覆盖

关键意义

模型学习的是“区域是否与输入短语匹配”，开放词汇能力来自大规模对齐数据与共享文本语义空间。

来源：Liu et al., Grounding DINO, Introduction, Sec. 3 and Appendix

消融证明：早期融合决定长尾泛化，三阶段设计共同起作用

Model	COCO zero-shot	COCO fine-tune	LVIS zero-shot
Full Grounding DINO-T	46.7	56.9	16.1
w/o encoder fusion	45.8	56.1	13.1
static query selection	46.3	56.6	13.6
w/o text cross-attention	46.1	56.3	14.3
word-level prompt	46.4	56.6	15.6

- Swin-L + O365/OI/GoldG 在不使用 COCO 训练图像时达到 **52.5 AP**；
- 在 COCO 微调后达到 62.6 AP，ODinW zero-shot 平均达到 26.1 AP；
- Encoder fusion 对 LVIS 的贡献最大，说明开放长尾类别需要更早、更充分的跨模态对齐。

来源：Liu et al., Grounding DINO, Abstract, Tables 2 and 7

- ① DETR 用 **object queries + Hungarian matching** 将检测重构为直接集合预测；
- ② DINO 用 **Mixed Query Selection** 找好位置起点，用 **CDN** 消除匹配混淆，用 **LFT** 改善跨层框优化；
- ③ Grounding DINO 用文本替代固定类别空间，并在 **特征、query 初始化、decoder** 三阶段持续融合语言；
- ④ 两者共享同一主干：动态 anchor + one-to-one matching + 逐层精修；区别在于 Grounding DINO 的分类目标由输入短语动态给出。

主线

传统检测在局部候选上做分类；DETR 用 query 预测物体集合；Grounding DINO 再用自然语言定义 query 要寻找的对象。

-  Girshick R, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation. *CVPR*, 2014.
-  Girshick R. Fast R-CNN. *ICCV*, 2015.
-  Ren S, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *TPAMI*, 2017.
-  Redmon J, et al. You Only Look Once: Unified, Real-Time Object Detection. *CVPR*, 2016.
-  Carion N, et al. End-to-End Object Detection with Transformers. *ECCV*, 2020.
-  Zhu X, et al. Deformable DETR. *ICLR*, 2021.
-  Liu S, et al. DAB-DETR. *ICLR*, 2022.
-  Li F, et al. DN-DETR. *CVPR*, 2022.
-  Zhang H, et al. DINO: DETR with Improved DeNoising Anchor Boxes. *ICLR*, 2023.
-  Liu S, et al. Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection. *ECCV*, 2024.

Thanks!