

RoFormer: Enhanced Transformer with Rotary Position Embedding

旋转位置编码 (RoPE)

韩成瑞

东南大学数学学院

2026 年 3 月 25 日



目录

- 1 绪论
- 2 研究背景
- 3 RoPE 核心推导
- 4 高效实现与远程衰减
- 5 实验与总结

目录

- 1 绪论
- 2 研究背景
- 3 RoPE 核心推导
- 4 高效实现与远程衰减
- 5 实验与总结

Neurocomputing 568 (2024) 127063



Contents lists available at [ScienceDirect](#)

Neurocomputing

journal homepage: www.elsevier.com/locate/neucom



RoFormer: Enhanced transformer with Rotary Position Embedding

Jianlin Su, Murtadha Ahmed*, Yu Lu, Shengfeng Pan, Wen Bo, Yunfeng Liu

Zhuiyi Technology Co., Ltd. Shenzhen, China



Jianlin Su received his master degree from Sun Yat-Sen University, Guangzhou, China. He is currently an NLP Researcher at Zhuiyi Technology Co., Ltd, Shenzhen. His current research interests focus on various NLP problems, including Pre-trained Language Models, Named-Entity Recognition, and Few-Shot Learning. One of his contribution to the research community is RoFormer: Enhanced Transformer with Rotary Position Embedding.

文章概述

- 核心贡献：提出**旋转位置编码 (RoPE)**，将绝对位置信息融入 self-attention，同时自然地表达相对位置关系
- 出发点：寻找一种位置编码方式，使得 attention 内积仅依赖于**相对位置** $m - n$
- 影响力：被 LLaMA、PaLM、Gemma、Qwen 等主流大语言模型广泛采用

博客出处

苏剑林. (2021). Transformer 升级之路：2、博采众长的旋转式位置编码.
<https://spaces.ac.cn/archives/8265>

目录

- 1 绪论
- 2 研究背景
- 3 RoPE 核心推导
- 4 高效实现与远程衰减
- 5 实验与总结

Self-Attention 回顾

给定输入序列 $\{x_1, x_2, \dots, x_N\}$, Self-Attention 的计算:

$$q_m = W_q x_m, \quad k_n = W_k x_n, \quad v_n = W_v x_n \quad (1)$$

$$a_{m,n} = \frac{\exp(\frac{q_m^\top k_n}{\sqrt{d}})}{\sum_{j=1}^N \exp(\frac{q_m^\top k_j}{\sqrt{d}})} \quad (2)$$

$$o_m = \sum_{n=1}^N a_{m,n} v_n \quad (3)$$

问题: 上述计算中没有位置信息——打乱顺序结果不变!

现有位置编码方法

绝对位置编码

- Sinusoidal PE (Vaswani et al.)
- 可学习位置向量
- 直接加到输入: $\tilde{x}_m = x_m + p_m$

缺点: 难以直接建模相对位置

相对位置编码

- Shaw et al. (2018)
- Transformer-XL
- DeBERTa
- 修改 attention score: 加入 R_{m-n}

缺点: 实现复杂, 破坏原始结构

RoPE 的目标

用绝对位置编码的形式, 实现相对位置编码的效果!

目录

- 1 绪论
- 2 研究背景
- 3 RoPE 核心推导**
- 4 高效实现与远程衰减
- 5 实验与总结

问题形式化

目标：找到位置编码函数 $f(\cdot, m)$ ，作用于 q, k 后，使得内积仅依赖相对位置：

$$\langle f(q, m), f(k, n) \rangle = g(q, k, m - n) \quad (4)$$

即 **attention score** 自然地只关注相对距离 $m - n$ 。

附加初始条件：

$$f(q, 0) = q, \quad f(k, 0) = k \quad (5)$$

数学视角：与再生核的联系

上述约束与再生核希尔伯特空间 (RKHS) 有深层联系：

核方法 (SVM)

$$K(x, y) = \langle \phi(x), \phi(y) \rangle$$

ϕ : 输入 $\rightarrow$ 特征空间

RoPE

$$\langle f(q, m), f(k, n) \rangle = g(q, k, m-n)$$

f : (向量, 位置) $\rightarrow$ 编码空间

RoPE 的约束恰好对应核理论中的 **平移不变核** (驻定核)：

$$K(x, y) = h(x - y)$$

由 **Bochner** 定理：平移不变正定核可表示为 Fourier 变换

$$h(x - y) = \int e^{i\omega(x-y)} d\mu(\omega) \quad (6)$$

RoPE 中的旋转 $e^{im\theta}$ 正是 **Fourier 基**——这不是巧合！

二维情形的求解（复数视角）——建模

当 $d = 2$ 时，将 $q = (q_0, q_1)$ 视为复数 $q_0 + q_1 i$ ，其极坐标形式为 $q = |q| e^{i\theta_q}$ 。

复数内积关系： $\langle q, k \rangle = \operatorname{Re}[q \cdot \bar{k}]$

设 $f(q, m) = R_f(q, m) e^{i\Theta_f(q, m)}$ （极坐标形式），则约束变为：

$$\operatorname{Re}[R_f(q, m) R_f(k, n) e^{i(\Theta_f(q, m) - \Theta_f(k, n))}] = g(q, k, m - n) \quad (7)$$

令 $m = n$ ，由初始条件 $g(q, k, 0) = \langle q, k \rangle = |q||k| \cos(\theta_q - \theta_k)$ ，对比可得：

$$R_f(q, m) = |q| \quad (\text{模长与位置无关}) \quad (8)$$

$$\Theta_f(q, m) - \Theta_f(k, m) = \theta_q - \theta_k \quad (\text{相位差与位置无关}) \quad (9)$$

二维情形的求解（复数视角）——求解

由 $\Theta_f(q, m) - \theta_q = \Theta_f(k, m) - \theta_k$ (对任意 q, k 成立), 可知:

$$\Theta_f(q, m) = \theta_q + \varphi(m) \quad (\varphi(m) \text{ 与 } q \text{ 无关}) \quad (10)$$

因此 $f(q, m) = |q| e^{i(\theta_q + \varphi(m))} = q \cdot e^{i\varphi(m)}$ 。代入约束:

$$\operatorname{Re}[q\bar{k} e^{i(\varphi(m) - \varphi(n))}] = g(q, k, m - n) \quad (11)$$

要求 $\varphi(m) - \varphi(n)$ 仅依赖 $m - n$, 即 $\varphi(m) - \varphi(n) = h(m - n)$ 。

Cauchy 函数方程的求解

已知 $\varphi(m) - \varphi(n) = h(m - n)$, 令 $n = 0$:

$$h(m) = \varphi(m) - \varphi(0) \quad (12)$$

代回原式: $\varphi(m) - \varphi(n) = \varphi(m - n) - \varphi(0)$

令 $\psi(m) = \varphi(m) - \varphi(0)$, 则:

$$\psi(m) - \psi(n) = \psi(m - n) \quad (13)$$

令 $m \rightarrow m + n$: $\psi(m + n) - \psi(n) = \psi(m)$, 即标准 **Cauchy** 方程:

$$\boxed{\psi(m + n) = \psi(m) + \psi(n)} \quad (14)$$

在可测 (或单调/连续) 条件下, **唯一解** 为 $\psi(m) = cm$ 。

因此 $\varphi(m) = cm + \varphi(0)$ 。由初始条件 $f(q, 0) = q$ 知 $\varphi(0) = 0$, 故:

$$\varphi(m) = m\theta \quad (\theta \text{ 为待定常数}) \quad (15)$$

二维 RoPE 解及几何意义

综合前面的推导, $f(q, m) = q \cdot e^{i\varphi(m)}$, 其中 $\varphi(m) = m\theta$:

二维 RoPE 解

$$f(q, m) = q e^{im\theta} \quad (16)$$

几何意义: 对向量 q 旋转角度 $m\theta$ —— 故称“**旋转位置编码**”

- 位置 m 处的编码 = 将原始向量旋转 $m\theta$ 角度
- 两个位置的内积: $\langle f(q, m), f(k, n) \rangle = \text{Re}[q\bar{k} e^{i(m-n)\theta}]$, 仅依赖 $m - n$ ✓

推广到高维：分组旋转

将 d 维空间分成 $d/2$ 个二维子空间，每个子空间独立旋转：

$$f(q, m) = \underbrace{\begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 & & & \\ \sin m\theta_1 & \cos m\theta_1 & & & \\ & & \cos m\theta_2 & -\sin m\theta_2 & \\ & & \sin m\theta_2 & \cos m\theta_2 & \\ & & & & \ddots \end{pmatrix}}_{R_{\Theta, m}} q \quad (17)$$

频率参数设定（类似 Sinusoidal PE）：

$$\theta_i = 10000^{-2(i-1)/d}, \quad i = 1, 2, \dots, d/2 \quad (18)$$

旋转矩阵的关键性质

① 正交性: $R_{\Theta,m}^\top = R_{\Theta,m}^{-1} = R_{\Theta,-m}$

② 相对位置自然体现:

$$q_m^\top k_n = (R_{\Theta,m} q)^\top (R_{\Theta,n} k) = q^\top R_{\Theta,m-n} k \quad (19)$$

内积仅依赖 $m - n$ ✓

目录

- 1 绪论
- 2 研究背景
- 3 RoPE 核心推导
- 4 高效实现与远程衰减
- 5 实验与总结

高效计算：避免矩阵乘法

RoPE 无需显式构造旋转矩阵，可通过逐元素乘法高效实现：

$$f(q, m) = \begin{pmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ \vdots \\ q_{d-2} \\ q_{d-1} \end{pmatrix} \otimes \begin{pmatrix} \cos m\theta_0 \\ \cos m\theta_0 \\ \cos m\theta_1 \\ \cos m\theta_1 \\ \vdots \\ \cos m\theta_{d/2-1} \\ \cos m\theta_{d/2-1} \end{pmatrix} + \begin{pmatrix} -q_1 \\ q_0 \\ -q_3 \\ q_2 \\ \vdots \\ -q_{d-1} \\ q_{d-2} \end{pmatrix} \otimes \begin{pmatrix} \sin m\theta_0 \\ \sin m\theta_0 \\ \sin m\theta_1 \\ \sin m\theta_1 \\ \vdots \\ \sin m\theta_{d/2-1} \\ \sin m\theta_{d/2-1} \end{pmatrix} \quad (20)$$

复杂度： $O(d)$ ，与不加位置编码时相同！

RoPE 内积可用复数形式简洁表达：

$$(\mathcal{R}_m q)^\top (\mathcal{R}_n k) = \operatorname{Re} \left[\sum_{i=0}^{d/2-1} \underbrace{q_{[2i:2i+1]} k_{[2i:2i+1]}^*}_{h_i} e^{i(m-n)\theta_i} \right] \quad (21)$$

- 每一项 $h_i e^{i(m-n)\theta_i}$ 是复平面上模为 $|h_i|$ 、方向为 $(m-n)\theta_i$ 的向量
- $|m-n|$ 小时：各项方向接近，求和**相长** $\Rightarrow$ 内积大
- $|m-n|$ 大时：不同频率 θ_i 使方向散开，求和**相消** $\Rightarrow$ 内积衰减

直觉

距离近 $\rightarrow$ 旋转因子对齐 $\rightarrow$ 关联强；距离远 $\rightarrow$ 相位散开 $\rightarrow$ 关联弱。
RoPE 自然地实现了“远处衰减”的先验，且衰减是平滑的，非硬截断。

目录

- 1 绪论
- 2 研究背景
- 3 RoPE 核心推导
- 4 高效实现与远程衰减
- 5 实验与总结**

实验结果

论文在多个任务上验证 RoPE 的有效性:

任务	对比方法	RoPE 表现
机器翻译 (WMT)	Sinusoidal, Learnable	持平或更优
预训练 (MLM)	BERT 绝对 PE, 相对 PE	持平或更优
中文 NER	BERT / NEZHA	取得最佳

- RoPE 具有良好的长度外推能力
- 实现简洁, 几乎不增加计算开销
- 后续工作: NTK-aware 外推、YaRN、动态 NTK 等

总结

RoPE 核心优势

- ① 用绝对位置的形式实现相对位置编码
- ② 基于旋转矩阵，数学上优雅，几何直觉清晰
- ③ 自然具备远程衰减特性
- ④ 实现高效，无额外参数， $O(d)$ 复杂度
- ⑤ 良好的序列长度外推潜力

后续影响

RoPE 已成为当前大语言模型（LLaMA、Qwen、Gemma 等）的标配位置编码方案，也推动了长上下文建模的进一步研究。

-  Su J, Lu Y, Pan S, et al. RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 2024, 568: 127063.
-  苏剑林. Transformer 升级之路: 2、博采众长的旋转式位置编码. 2021. <https://spaces.ac.cn/archives/8265>
-  Vaswani A, et al. Attention is all you need. *NeurIPS*, 2017.
-  Shaw P, Uszkoreit J, Vaswani A. Self-attention with relative position representations. *NAACL*, 2018.

Thanks!